

PROYECTO DE ANALÍTICA DE DATOS

Predicción de Ventas con Machine Learning

Dataset:	BMW Global Sales 2018–2025
Modelo:	Regresión Lineal (scikit-learn)
Herramienta:	Google Colab — Python 3
Curso:	BI y Big Data — Nivel 3
Reto:	Reto 4: Aplicación de IA en la predicción de ventas

Informe técnico de resultados

1. Introducción

El presente proyecto tiene como objetivo desarrollar un modelo predictivo capaz de estimar las ventas de vehículos de la marca BMW utilizando técnicas de Machine Learning. Para ello se ha utilizado un conjunto de datos de ventas globales correspondiente al período 2018–2025, extraído de Kaggle.

Este tipo de análisis permite identificar patrones en los datos históricos y utilizar esa información para generar predicciones que apoyen la toma de decisiones empresariales: planificación de inventario, previsión de demanda o estimación de ingresos futuros.

El proyecto sigue el flujo estándar de un proceso de analítica de datos:

#	Fase	Descripción
1	Exploración del dataset	Revisión preliminar: estructura, tipos de datos, valores nulos y rango temporal.
2	Preparación de los datos	Limpieza, creación de columna Date (referencia), eliminación de columnas no necesarias y codificación One-Hot Encoding.
3	Entrenamiento del modelo	División 80/20, entrenamiento con Regresión Lineal en Google Colab (scikit-learn).
4	Evaluación del modelo	Cálculo de métricas MAE, RMSE y R ² sobre el conjunto de datos de prueba.
5	Interpretación de resultados	Comparación visual de predicciones vs. valores reales mediante gráfico de dispersión.

A continuación se muestra el dataset tal como fue visualizado inicialmente en Microsoft Excel, antes de iniciar cualquier transformación:




Figura 1. Visualización inicial del archivo CSV en Microsoft Excel

2. Descripción del Dataset


El dataset contiene 3.072 registros de ventas globales de vehículos BMW, organizados por modelo, región geográfica y período temporal (año y mes). Cada fila representa la agregación mensual de ventas para una combinación específica de modelo y región.

Las variables originales del dataset son las siguientes:

Variable	Descripción
Year	Año en el que se registró la venta.
Month	Mes en el que se produjo la venta.
Region	Región geográfica: Europe, China, USA, RestOfWorld.
Model	Modelo de vehículo: 3 Series, 5 Series, X3, X5, X7, i4, iX, MINI.
Units_Sold	Número de unidades vendidas — variable objetivo del modelo.
Avg_Price_EUR	Precio medio del vehículo en euros.
Revenue_EUR	Ingresos totales generados por las ventas.

Durante la fase de preparación se creó una columna auxiliar **Date** (con formato mes-año, por ejemplo *enero-18*) con fines de referencia temporal. Sin embargo, esta columna fue eliminada del conjunto de features antes del entrenamiento, ya que la información temporal queda correctamente representada a través de las columnas **Year** y **Month**, que son las que el modelo utiliza como variables predictoras numéricas.

Las columnas **Revenue_EUR** y **Avg_Price_EUR** fueron retenidas como variables explicativas, ya que aportan contexto económico relevante sobre la dinámica de ventas por modelo y región.



	A	B	C	D	E	F	G	H	I
1	Year	Month	Region	Model	Units_Sold	Avg_Price_EUR	Revenue_EUR		
2	2018	1	Europe	3 Series	7822	47.482,00 €	371.404.204,00 €		
3	2018	1	Europe	5 Series	10280	61.685,00 €	634.121.800,00 €		
4	2018	1	Europe	X3	3105	58.433,00 €	181.434.465,00 €		
5	2018	1	Europe	X5	7420	67.955,00 €	504.226.100,00 €		
6	2018	1	Europe	X7	8474	82.200,00 €	702.150.200,00 €		

Figura 2. Dataset preparado en Excel con columnas seleccionadas y formato tabular

3. Preparación de los Datos

Antes de entrenar el modelo fue necesario preparar los datos para que pudieran ser procesados correctamente por los algoritmos de Machine Learning. La calidad del modelo depende directamente de la calidad de los datos de entrada.

3.1 Revisión y limpieza

Se realizó una revisión exhaustiva del dataset para detectar posibles valores nulos, duplicados o inconsistencias. Tras esta revisión se confirmó que el dataset no presentaba valores nulos en ninguna de sus columnas, y que la frecuencia temporal era mensual y regular para todo el período 2018–2025.

3.2 Transformaciones aplicadas

Las principales transformaciones realizadas sobre el dataset fueron las siguientes:

- Creación de la columna **Date** (formato mes-año) con propósito informativo, eliminada antes del modelado.
- Codificación **One-Hot Encoding** sobre las variables categóricas *Region* y *Model*, transformándolas en variables numéricas binarias.
- Separación de la variable objetivo (**Units_Sold**) del resto de variables predictoras.

3.3 Entorno y bibliotecas

El entorno utilizado fue **Google Colab**. Las bibliotecas empleadas fueron:

- **Pandas** — manipulación y transformación de datos estructurados.
- **NumPy** — operaciones matemáticas y vectoriales.
- **Scikit-learn** — entrenamiento, evaluación y métricas del modelo.
- **Matplotlib** — generación de visualizaciones.

La siguiente captura muestra el estado del dataset una vez cargado en Python y aplicadas las primeras transformaciones:

```
[29] ✓ 0s
import pandas as pd
import numpy as np

from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

[38] ✓ 0s
df = pd.read_csv("bmw_global_sales_2018_2025_CLEAN.csv", encoding='latin1', sep=';')
df.columns = df.columns.str.strip()
df.head()
```

	Year	Month	Date	Region	Model	Units_Sold	Avg_Price_EUR	Revenue_EUR
0	2018	1	enero-18	Europe	3 Series	7822	47.482,00	371.404.204,00
1	2018	1	enero-18	Europe	5 Series	10280	61.685,00	634.121.800,00
2	2018	1	enero-18	Europe	X3	3105	58.433,00	181.434.465,00
3	2018	1	enero-18	Europe	X5	7420	67.955,00	504.226.100,00
4	2018	1	enero-18	Europe	X7	8474	92.300,00	782.150.200,00

Pasos siguientes: [Generar código con df](#) [New interactive sheet](#)

Figura 3. Dataset cargado en Google Colab con columna Date y variables preparadas

4. Entrenamiento del Modelo

Para el desarrollo del modelo predictivo se optó por un algoritmo de **Regresión Lineal**, un modelo supervisado que establece relaciones lineales entre las variables de entrada y la variable objetivo. Esta elección resulta adecuada como punto de partida dado que el dataset presenta una estructura regular y una distribución de la variable objetivo sin outliers extremos.


4.1 División del dataset

El dataset fue dividido en dos subconjuntos de forma aleatoria pero reproducible (*random_state=42*):

- **Datos de entrenamiento (80%)** — utilizados para ajustar los coeficientes del modelo.
- **Datos de prueba (20%)** — reservados exclusivamente para evaluar el rendimiento sobre datos no vistos.

4.2 Proceso de entrenamiento

El modelo **LinearRegression** de scikit-learn fue instanciado y entrenado sobre el conjunto de entrenamiento mediante el método *fit()*. Las variables predictoras incluyen Year, Month, Avg_Price_EUR, Revenue_EUR y todas las columnas generadas por el One-Hot Encoding de Region y Model.



```
[33] X_train, X_test, y_train, y_test = train_test_split(  
      X, y, test_size=0.2, random_state=42  
      )  
[34] model = LinearRegression()  
[35] model.fit(X_train, y_train)
```

The screenshot shows three code cells in Google Colab. The first cell splits the data into training and testing sets using `train_test_split` with `test_size=0.2` and `random_state=42`. The second cell instantiates a `LinearRegression` model. The third cell calls `model.fit(X_train, y_train)` to train the model. Below the third cell, a dropdown menu for `LinearRegression` is open, showing the class name `LinearRegression()`.

Figura 4. Código de división del dataset y entrenamiento del modelo en Google Colab

5. Evaluación del Modelo

Una vez entrenado el modelo, se generaron predicciones sobre el conjunto de prueba y se compararon con los valores reales mediante tres métricas estándar en proyectos de regresión.

Métrica	Valor obtenido	Interpretación
MAE	481,76 unidades	Error medio absoluto por predicción
RMSE	690,13 unidades	Penaliza errores grandes de forma adicional
R ²	0,952	El modelo explica el 95,2% de la variabilidad de ventas

5.1 Interpretación de los resultados

MAE = 481,76 unidades: En promedio, el modelo se equivoca en aproximadamente 482 unidades por predicción. Sobre una media de ventas de ~7.980 unidades mensuales, esto supone un error relativo de apenas el **6%**, un resultado muy satisfactorio.

RMSE = 690,13 unidades: Al ser superior al MAE, indica que existen algunas predicciones con errores mayores que la media. No obstante, el valor sigue siendo razonable en relación con la magnitud de las ventas del dataset.

R² = 0,952: El modelo explica el **95,2%** de la variabilidad de los datos de ventas. Este valor es excepcionalmente alto para un modelo de regresión lineal, confirmando que las variables predictoras seleccionadas tienen una fuerte capacidad explicativa.

La siguiente captura muestra el código de evaluación y los valores de las métricas obtenidos en Google Colab:




Figura 5. Comparación de predicciones vs. valores reales y métricas de evaluación en Google Colab

6. Visualización de Resultados

Para facilitar la interpretación del rendimiento del modelo se generó un **gráfico de dispersión** que enfrenta los valores reales de ventas (eje horizontal) con los valores predichos por el modelo (eje vertical).

En este tipo de representación, un modelo perfecto situaría todos los puntos exactamente sobre la diagonal (pendiente 45°). Cuanto más compacta y alineada con esa diagonal sea la nube de puntos, mejor es el ajuste del modelo.

En el gráfico obtenido se observa que:

- La mayoría de los puntos se agrupan de forma muy ajustada alrededor de la diagonal, confirmando el alto R^2 obtenido.
- En el rango de ventas bajas (2.000–5.000 unidades) existe algo más de dispersión: el modelo tiene más dificultad con los valores extremos inferiores.
- En el rango medio y alto (5.000–16.000 unidades) el ajuste es notablemente preciso.




Figura 6. Gráfico de dispersión: Ventas reales vs. Ventas predichas por el modelo

7. Conclusiones

En este proyecto se ha desarrollado con éxito un modelo de Machine Learning basado en Regresión Lineal capaz de estimar el volumen de ventas mensuales de vehículos BMW por modelo y región geográfica, utilizando datos históricos del período 2018–2025.

Los resultados obtenidos son notablemente positivos:

- Un coeficiente de determinación **R^2 de 0,952** confirma que el modelo captura con gran fidelidad los patrones de ventas.
- Un error medio absoluto (MAE) de ~482 unidades sobre una media de ~7.980 unidades supone un **error relativo inferior al 6%**.
- La visualización predicciones vs. reales ratifica visualmente el alto grado de ajuste del modelo.

7.1 Valor para el negocio

Este tipo de modelo tiene aplicaciones directas en el ámbito empresarial. Una herramienta predictiva con estas características permitiría a una organización como BMW:

- Planificar la producción y el inventario de forma anticipada, reduciendo costes y evitando roturas de stock.
- Optimizar la asignación de recursos comerciales por región y modelo en función de la demanda prevista.
- Detectar con antelación desviaciones respecto a los objetivos de ventas y activar medidas correctoras.
- Mejorar la precisión de las previsiones financieras trimestrales y anuales.

7.2 Líneas de mejora futuras

Como posibles mejoras a implementar en iteraciones futuras del modelo se proponen:

- Incorporar modelos más complejos como **Random Forest** o **Gradient Boosting**, que capturan relaciones no lineales.
- Añadir variables externas del dataset original: *BEV_Share*, *GDP_Growth* y *Fuel_Price_Index*.
- Implementar una **validación cruzada temporal** para evaluar la robustez ante diferentes períodos del ciclo económico.
- Desarrollar modelos específicos por región o familia de modelos para capturar mejor las particularidades de cada mercado.

— Fin del informe —